Optimización Unidimensional Aplicada a Regresión Lineal: Modelado de Costos Inmobiliarios

Kristopher Vela Domínguez
Ingeniería en Inteligencia Artificial
Universidad de Xalapa
Xalapa, Veracruz, México

***Resumen*—En el presente trabajo se aborda el ajuste de un modelo de Regresión Lineal Simple abordado desde la perspectiva de la optimización unidimensional. El objetivo fue minimizar la función de Suma de Errores al Cuadrado (SSE) para encontrar la relación entre el área de una propiedad y su costo de renta. Mediante la técnica de centrado de datos, el problema bidimensional (β_0, β_1) se redujo a la optimización exclusiva de la pendiente (β_1). Se implementó el algoritmo de la Sección Áurea bajo el paradigma de Programación Orientada a Objetos, garantizando la convergencia al mínimo global dentro de una tolerancia de $0{,}001$.**

***Index Terms*—Regresión Lineal, Optimización unidimensional, Sección Áurea, Suma de Errores al Cuadrado, POO.**

I. Introducción

La regresión lineal es un modelo estadístico y de aprendizaje automático que busca encontrar la recta continua que mejor generalice la tendencia de un conjunto de datos observados. La formulación matemática clásica está dada por la ecuación:

$$y = \beta_1 x + \beta_0 \tag{1}$$

Donde β_1 representa la pendiente (tasa de incremento del costo por metro cuadrado) y β_0 la intersección con el eje Y.

El método de Mínimos Cuadrados Ordinarios busca minimizar el error entre la predicción de la recta y los datos reales. Para aplicar las técnicas de optimización unidimensional desarrolladas en clase, se requiere una transformación inicial sobre el dataset, eliminando temporalmente la dependencia de la intersección.

II. Metodología

II-A. Centrado de Datos

Para simplificar la función de costo, el sistema original fue trasladado al origen $(0, 0)$. Este proceso matemático consiste en calcular el promedio de los metros cuadrados ($\bar{x}$) y de las rentas ($\bar{y}$), y restarlos de cada observación:

$$x'_i = x_i - \bar{x} \tag{2}$$

$$y'_i = y_i - \bar{y} \tag{3}$$

Con esto, la recta pasa forzosamente por el origen en el nuevo plano centrado, permitiendo modelar las predicciones simplemente como $y' = \beta_1 x'$.

II-B. Función Objetivo (SSE)

El problema de optimización se define como la búsqueda del escalar β_1 que minimice la Suma de Errores al Cuadrado (SSE):

$$\text{Minimizar } SSE(\beta_1) = \sum_{i=1}^{n} (y'_i - \beta_1 x'_i)^2 \tag{4}$$

II-C. Algoritmo de Optimización

La minimización se resolvió mediante una implementación Orientada a Objetos del método de la **Sección Áurea**. Se configuró el dominio de búsqueda en el intervalo $[0, 1]$ con una tolerancia estricta de detención de $\Delta < 0{,}001$.

III. Resultados y Análisis Visual

Tras ejecutar el algoritmo, el método iterativo convergió exitosamente, devolviendo como resultado óptimo una pendiente de $\beta_1 \approx 0{,}29837$. Esto indica matemáticamente que por cada metro cuadrado adicional, la renta incrementa en aproximadamente $0{,}29837$ unidades financieras (miles de dólares).

Despejando analíticamente la intersección original mediante la fórmula $\beta_0 = \bar{y} - \beta_1 \bar{x}$, se obtuvo un costo base de $\beta_0 \approx -0{,}31942$. El error mínimo alcanzado (SSE) fue de $1{,}95742$.

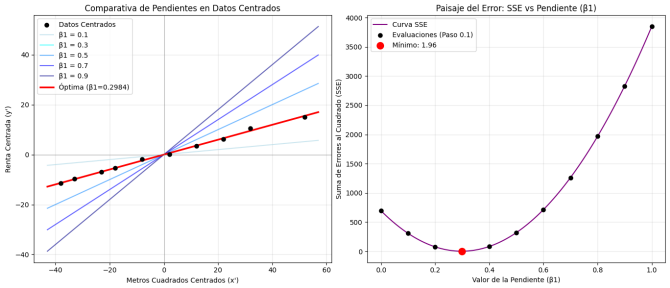

Figura 1. Izquierda: Comparativa de líneas de ajuste con distintas pendientes evaluadas sobre los datos centrados (el ajuste óptimo se resalta en rojo). Derecha: Paisaje del Error (SSE), evidenciando la convexidad estricta de la función objetivo y la localización del mínimo global.

Como se observa en el panel derecho de la Figura 1, la función de costo (SSE) presenta una clara forma de parábola convexa (unimodal). El gráfico verifica las evaluaciones de la función en pasos de 0.1, demostrando visualmente por qué los

métodos de eliminación de regiones son altamente efectivos para este tipo de topologías.

IV. Conclusión

Se demostró con éxito cómo un problema clásico de Machine Learning predictivo puede solucionarse de manera iterativa utilizando fundamentos puros de optimización unidimensional. El centrado de datos resultó ser una estrategia matemática crucial para reducir la dimensionalidad del problema, permitiendo que algoritmos altamente eficientes como la Sección Áurea encontraran el gradiente óptimo con absoluta precisión.